ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC - KỸ THUẬT MÁY TÍNH

XÁC SUẤT THỐNG KÊ

Báo cáo Bài tập lớn

Cancer Regression

GVHD: PGS. TS. Nguyễn Đình Huy
SV: Yeh Tzu - 2353305
Lê Trần Như Quỳnh - 2353038
Trần Đức Khôi Nguyên - 2352837
Nguyễn Ngọc Lan Vy - 2353358
Đinh Trần Anh Khoa - 2352553
Nguyễn Lê Minh Nhật - 2352860

TP. HỒ CHÍ MINH, THÁNG 4/2025

Bảng phân công			
STT	HỌ VÀ TÊN	MSSV	NHIỆM VỤ
1	Yeh Tzu	2353305	Mục 5, chỉnh sửa nội dung và định dạng
2	Nguyễn Ngọc Lan Vy	2353358	Mục 1
3	Lê Trần Như Quỳnh	2353038	Mục 2 và mục 3
4	Trần Đức Khôi Nguyên	2352837	Code R
5	Đinh Trần Anh Khoa	2352553	Mục 4
6	Nguyễn Lê Minh Nhật	2352860	Mục 6

LỜI CẢM ƠN

Trước khi bắt đầu bài tiểu luận này, nhóm 11 lớp CN02 xin được gửi lời cảm ơn đến Trường Đại học Bách Khoa TP.HCM đã đưa bộ môn Xác suất và Thống kê vào chương trình giảng dạy để chúng em có cơ hội tiếp thu kiến thức quý giá. Và hơn hết, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy Nguyễn Đình Huy (giảng viên bộ môn) – người đã luôn tận tụy, kiên nhẫn và nhiệt huyết trong quá trình giảng dạy.

Cảm ơn thầy đã luôn truyền đạt cho chúng em kiến thức bằng cả tất cả tâm huyết. Thầy không chỉ là người giảng dạy mà còn là người đồng hành, luôn quan tâm, động viên và hỗ trợ chúng em một cách chân thành. Thời gian học bộ môn của thầy là khoảng thời gian tuyệt vời, vì chúng em không chỉ được học lý thuyết mà còn nắm bắt được những kinh nghiệm thực tế hữu ích. Đây sẽ là hành trang để chúng em có thể vững bước trên con đường đã lựa chọn ban đầu.

Bộ môn Xác suất và Thống kê không chỉ bổ ích mà còn có tính thực tế cao. Trong quá trình thực hiện bài tiểu luận, chúng em đã có cơ hội vận dụng những kiến thức đã học để phân tích, đánh giá và suy luận thống kê – một trải nghiệm tuy đầy thử thách nhưng vô cùng thú vị và bổ ích. Tuy nhiên, do vốn kiến thức còn nhiều hạn chế và khả năng tiếp thu thực tế còn nhiều bỡ ngỡ, mặc dù chúng em đã cố gắng hết sức nhưng chắc chắn bài tiểu luận khó có thể tránh khỏi những thiếu sót và nhiều chỗ còn chưa chính xác, kính mong thầy xem xét và góp ý để bài tiểu luận của em được hoàn thiện hơn. Chúng em cũng xin gửi lời cảm ơn chân thành đến gia đình, bạn bè, các anh/chị khóa trên vì đã luôn động viên, quan tâm giúp đỡ chúng em trong quá trình học tập và thực hiện bài tiểu luận.
Lời cuối cùng, nhóm 11 xin kính chúc thầy nhiều sức khỏe, thành công và hạnh phúc.

Mục lục

1 Tổng quan dữ liệu **4**
1.1 Ngữ cảnh của dữ liệu . . . 4
1.2 Bảng mô tả các biến trong dữ liệu . . . 4

2 Kiến thức nền **6**
2.1 Các nguyên lý của kiểm định giả thuyết thống kê . . . 6
2.1.1 Giả thuyết không H_0 và giả thuyết đối H_1 . . . 6
2.1.2 Kiểm định một mẫu (hai phía, trái và phải) . . . 6
2.1.3 Kiểm định hai mẫu . . . 7
2.1.3.a Kiểm định kỳ vọng hai mẫu độc lập (hai phía, trái và phải) . . . 7
2.2 Phân tích hồi quy . . . 8
2.2.1 Hồi quy tuyến tính đơn . . . 8
2.2.2 Hồi quy tuyến tính bội . . . 8
2.2.2.a Các giả thuyết của mô hình hồi quy bội . . . 9
2.2.2.b Phương pháp bình phương nhỏ nhất (OLS) . . . 9
2.2.3 Độ phù hợp của hàm hồi quy . . . 10
2.2.4 Khoảng tin cậy và kiểm định các hệ số hồi quy . . . 11
2.3 Phân tích phương sai một yếu tố (Anova một nhân tố với cỡ mẫu cân bằng) . . . 11

3 Tiền xử lí số liệu **14**
3.1 Đọc dữ liệu . . . 14
3.2 Làm sạch dữ liệu . . . 14
3.2.1 Chọn lọc dữ liệu . . . 14
3.2.2 Thêm và xóa biến . . . 15
3.3 Xử lý dữ liệu khuyết . . . 15

4 Thống kê mô tả **17**
4.1 Tính toán thống kê mẫu . . . 17
4.2 Mô tả dữ liệu bằng đồ thị . . . 19
4.2.1 Histogram (Biểu đồ tần suất) . . . 19
4.2.2 Boxplot (Biểu đồ hộp) . . . 20
4.2.3 Scatter Plot (Biểu đồ phân tán) . . . 21

5 Thống kê suy diễn **22**
5.1 Phân tích các hệ số tương quan Pearson giữa các biến trong tập dữ liệu và tỷ lệ ung thư tại Mỹ . . . 22
5.1.1 Mục tiêu . . . 22
5.1.2 Thực hiện . . . 22
5.1.3 Kết quả . . . 23
5.1.4 Nhận xét . . . 24
5.2 So sánh số lượng ca mắc ung thư được chẩn đoán hằng năm tại các bang ở Mỹ . . . 24
5.2.1 Mục tiêu . . . 24
5.2.2 Kết quả . . . 24
5.2.3 Nhận xét . . . 24
5.3 Phân tích ảnh hưởng của các biến độc lập đến số ca tử vong vì ung thư tại Mỹ . . . 25
5.3.1 Mục tiêu . . . 25
5.3.2 Kết quả . . . 26
5.3.3 Nhận xét . . . 26

6 Thảo luận và mở rộng **27**
6.1 Phân tích phương sai (ANOVA một nhân tố, cỡ mẫu cân bằng) . . . 27
6.2 Phân tích hồi quy . . . 27
6.2.1 Hồi quy tuyến tính đơn . . . 27
6.2.2 Hồi quy tuyến tính bội . . . 27

1 Tổng quan dữ liệu

1.1 Ngữ cảnh của dữ liệu

Bộ dữ liệu **Cancer Regression** được xây dựng nhằm phân tích mối liên hệ giữa các yếu tố kinh tế - xã hội, y tế và tỷ lệ tử vong do ung thư tại các khu vực dân cư ở Hoa Kỳ.

Mục tiêu chính là sử dụng các biến như thu nhập trung bình, tỷ lệ đói nghèo, dân số, tỷ lệ người có bảo hiểm y tế,... để dự đoán tỷ lệ tử vong do ung thư (biến mục tiêu là `target_deathrate`).

Bộ dữ liệu gồm 3.047 dòng, tương ứng với 3.047 khu vực địa lý khác nhau, và 33 cột, đại diện cho các biến định tính và định lượng mô tả đặc điểm của từng khu vực. Dữ liệu được tổng hợp từ nhiều nguồn công khai uy tín tại Hoa Kỳ như Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh (CDC), Cục điều tra dân số Hoa Kỳ, và các hệ thống dữ liệu bảo hiểm y tế.

Tuy không có mô tả chi tiết kèm theo trong tệp, nhưng đây là dạng dữ liệu phổ biến trong nghiên cứu y tế cộng đồng và dịch tễ học.

1.2 Bảng mô tả các biến trong dữ liệu

Biến	Loại	Mô tả thống kê / Ví dụ	Ý nghĩa
avganncount	Rời rạc	TB: 606.34, ĐLC: 1416.36, Min–Max: 6–38,150	Số ca ung thư trung bình hàng năm
avgdeathsperyear	Rời rạc	TB: 185.97, ĐLC: 504.13, Min–Max: 3–14,010	Số ca tử vong trung bình hàng năm
target_deathrate	Liên tục	TB: 178.66, ĐLC: 27.75, Min–Max: 59.7–362.8	Biến mục tiêu: Tỷ lệ tử vong do ung thư
incidencerate	Liên tục	TB: 448.27, ĐLC: 54.56, Min–Max: 201.3–1206.9	Tỷ lệ mắc bệnh
medincome	Rời rạc	TB: 47,063.28, ĐLC: 12,040.09, Min–Max: 22,640–125,635	Thu nhập trung vị
popest2015	Rời rạc	TB: 102,637.37, ĐLC: 329,059.22, Min–Max: 827–10,170,290	Dân số ước tính năm 2015
povertypercent	Liên tục	TB: 16.88, ĐLC: 6.41, Min–Max: 3.2–47.4	Tỷ lệ nghèo đói
medianage	Liên tục	TB: 45.27, ĐLC: 45.30, Min–Max: 22.3–624	Tuổi trung vị (có ngoại lệ)
pctwhite	Liên tục	TB: 82.14, ĐLC: 20.02, Min–Max: 2.2–99.7	Tỷ lệ người da trắng
pctblack	Liên tục	TB: 9.44, ĐLC: 17.23, Min–Max: 0–87.4	Tỷ lệ người da đen
pctasian	Liên tục	TB: 1.62, ĐLC: 3.18, Min–Max: 0–46.8	Tỷ lệ người châu Á
pctotherrace	Liên tục	TB: 6.62, ĐLC: 11.41, Min–Max: 0.2–97.3	Tỷ lệ các dân tộc khác
birthrate	Liên tục	TB: 12.15, ĐLC: 1.80, Min–Max: 4.4–20.7	Tỷ lệ sinh
percentmarried	Liên tục	TB: 51.77, ĐLC: 6.90, Min–Max: 23.1–72.5	Tỷ lệ người đã kết hôn
pctnohs18_24	Liên tục	TB: 18.22, ĐLC: 8.09, Min–Max: 0–64.1	Tỷ lệ 18–24 tuổi không học hết THPT
pcths18_24	Liên tục	TB: 35.00, ĐLC: 9.07, Min–Max: 0–72.5	Tỷ lệ học hết THPT
pctsomecol18_24	Liên tục	TB: 40.98, ĐLC: 11.12, Min–Max: 7.1–79.0	Tỷ lệ đang học cao đẳng/đại học
geography	Phân loại	VD: "Autauga, AL"	Tên địa phương (quận, bang)
stateabbr	Phân loại	VD: "AL", "CA", "TX"	Mã bang
binnedinc	Phân loại	VD: "[25000, 30000)", "[45000, 50000)"	Khoảng thu nhập phân nhóm
urbanrural	Phân loại	VD: 1, 2, 3	Mức độ đô thị hóa
countycode	Phân loại	VD: 1, 3, 5,...	Mã quận
fipscode	Phân loại	VD: 1001, 1003,...	Mã định danh theo FIPS

Bảng 1: Bảng mô tả các biến trong bộ dữ liệu Cancer Regression

2 Kiến thức nền

2.1 Các nguyên lý của kiểm định giả thuyết thống kê

2.1.1 Giả thuyết không H_0 và giả thuyết đối H_1

Theo lý thuyết ta có:

- H_0 (Giả thuyết không): Dữ liệu được rút ra từ một phân phối chuẩn, biểu diễn trạng thái ban đầu hoặc không có sự thay đổi khác biệt nào.

- (Giả thuyết đối): Mô tả sự khác biệt, tức là dữ liệu không được rút ra từ một phân phối chuẩn. Các dạng giả thuyết đối:

- Hai phía (H_1: $\mu \neq \mu_0$): Trung bình khác giá trị giả định.
- Phía phải (H_1: $\mu > \mu_0$): Trung bình lớn hơn giá trị giả định.
- Phía trái (H_1: $\mu < \mu_0$): Trung bình nhỏ hơn giá trị giả định.

2.1.2 Kiểm định một mẫu (hai phía, trái và phải)

Kiểm định Z: Dùng phân phối chuẩn tắc để kiểm định. Z_α là điểm phân vị bên phải mức α của phân phối chuẩn tắc (chọn giá trị gần nhất trong bảng, làm tròn đến 2 chữ số sau dấu phẩy).

Kiểm định t: Dùng phân phối Student để kiểm định. t_α là điểm phân vị bên phải mức α của phân phối Student (chọn giá trị gần nhất trong bảng, làm tròn đến 3 chữ số sau dấu phẩy).

Ta có các công thức:

(a) Khi kỳ vọng của phân phối chuẩn đã biết phương sai σ^2 (biết độ lệch chuẩn σ):

$$Z = \frac{\bar{X} - \mu_0}{SE} \qquad SE = \frac{\sigma}{\sqrt{n}}$$

(b) Khi kỳ vọng của phân phối chuẩn nhưng không biết phương sai σ^2 (dùng mẫu để ước lượng):

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

Trong đó:

- μ: Kỳ vọng.
- $\bar{X}$: Trung bình mẫu.
- σ^2: Phương sai tổng thể.
- s^2: Phương sai mẫu.
- SE: Sai số chuẩn (tổng thể), $SE = \dfrac{\sigma}{\sqrt{n}}$.
- se: Sai số chuẩn (mẫu), $se = \dfrac{s}{\sqrt{n}}$.

Ta có các trường hợp như sau:

(a) Khi $n \geq 30$:

- Với kiểm định hai phía, miền bác bỏ là: $|Z| > Z_{\alpha/2}$.
- Với kiểm định một phía, miền bác bỏ là: $Z > Z_\alpha$ hoặc $Z < -Z_\alpha$.

(b) Khi $n < 30$:

- Kiểm định một phía:
  - Nếu $T \leq t_\alpha$: chấp nhận H_0.
  - Nếu $T > t_\alpha$: bác bỏ H_0.
- Kiểm định hai phía:
  - Nếu $t < -t_{\alpha/2}$ hoặc $t > t_{\alpha/2}$: bác bỏ H_0.
  - Nếu $-t_{\alpha/2} \leq t \leq t_{\alpha/2}$: không bác bỏ H_0.

Kết luận kiểm định: Bác bỏ hoặc không bác bỏ H_0, với mức ý nghĩa phổ biến là $\alpha = 0.05$.

2.1.3 Kiểm định hai mẫu

2.1.3.a Kiểm định kỳ vọng hai mẫu độc lập (hai phía, trái và phải)

Giả thuyết kiểm định:

- H_0: $\mu_1 = \mu_2$ — Không có sự khác biệt giữa kỳ vọng hai tổng thể.
- H_1: $\mu_1 \neq \mu_2$ — Có sự khác biệt giữa kỳ vọng hai tổng thể.

(a) Hai kỳ vọng của phân phối chuẩn, biết σ_1 và σ_2:

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

(b) Hai kỳ vọng của phân phối chuẩn, không biết σ_1 và σ_2 (dùng phương sai mẫu):

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Dựa vào công thức trên, ta xét tiếp 2 trường hợp:

- Nếu $\frac{s_1}{s_2} \in [0.5, 2]$: giả định phương sai bằng nhau.
- Nếu không: giả định phương sai khác nhau.

(b1) Phương sai bằng nhau: $\sigma_1^2 = \sigma_2^2$

Ước lượng phương sai chung:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Thống kê kiểm định:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

(b2) Phương sai khác nhau: $\sigma_1^2 \neq \sigma_2^2$

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Số bậc tự do xấp xỉ:

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2-1}}$$

Trong đó:

- μ_1, μ_2: Kỳ vọng tổng thể.
- $\bar{X}_1, \bar{X}_2$: Trung bình mẫu.
- σ_1^2, σ_2^2: Phương sai tổng thể.
- s_1^2, s_2^2: Phương sai mẫu.
- s_p^2: Phương sai mẫu chung.
- SE, se: Sai số chuẩn tổng thể/mẫu.

Tìm giá trị tới hạn:

- Z_α: từ hệ thức $2\Phi(Z_\alpha) = 1 - \alpha$ (phân phối chuẩn).
- t_α: từ bảng phân phối Student với bậc tự do phù hợp.

Miền bác bỏ:

- Kiểm định hai phía: $|t| > t_{\alpha/2}$.
- Kiểm định phía phải: $t > t_\alpha$.
- Kiểm định phía trái: $t < -t_\alpha$.

2.2 Phân tích hồi quy

Định nghĩa: Phân tích hồi quy là một phương pháp thống kê được sử dụng để nghiên cứu và mô hình hóa mối quan hệ giữa biến phụ thuộc (dependent variable) và biến độc lập (independent variable(s))

- Biến phụ thuộc : Là biến mà ta muốn dự đoán hoặc giải thích.
- Biến độc lập: Là các yếu tố đầu vào ảnh hưởng đến biến phụ thuộc.

2.2.1 Hồi quy tuyến tính đơn

Một mô hình thống kê tuyến tính đơn liên quan đến một biến ngẫu nhiên Y và một biến giải thích X là phương trình có dạng:

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

Trong đó β_0, β_1 lần lượt là hệ số chặn và hệ số góc, và được gọi là tham số hồi quy, ε là sai số ngẫu nhiên và X là biến độc lập, giải thích cho biến phụ thuộc Y.
Mô hình này không dựa trên lí thuyết, mà dựa trên dữ liệu, sự lựa chọn mô hình sau khi xây dựng sơ đồ phân tán, nên được gọi là mô hình thực nghiệm.

2.2.2 Hồi quy tuyến tính bội

Định nghĩa: Hồi quy tuyến tính bội là mở rộng của hồi quy tuyến tính đơn. Hồi quy tuyến tính bội là nghiên cứu về mối liên hệ của biến phụ thuộc Y cho trước với nhiều biến độc lập X. Mô hình này có dạng tổng quát như sau:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \cdots + \beta_k X_k + \varepsilon$$

Trong đó:

- X_j: các biến độc lập.
- ε: sai số ngẫu nhiên, đại diện cho các yếu tố có tác động đến Y.
- β_0: hệ số chặn.
- β_j: hệ số góc thể hiện ảnh hưởng của riêng từng biến độc lập X_j lên Y khi các biến khác được giữ không đổi. Cụ thể, khi X_j tăng hoặc giảm 1 đơn vị, trong điều kiện các biến độc lập khác không đổi, thì Y trung bình sẽ thay đổi β_j đơn vị.

Có thể nhận thấy ba trường hợp có thể xảy ra đối với các hệ số góc:

- Hệ số $\beta_j > 0$: Mối quan hệ giữa Y và X_j là thuận chiều.
- Hệ số $\beta_j < 0$: Mối quan hệ giữa Y và X_j là ngược chiều.
- Hệ số $\beta_j = 0$: Có thể cho rằng giữa Y và X_j không có tương quan.

Dựa vào kết quả ước lượng với một mẫu cụ thể, ta có thể đánh giá được mối quan hệ giữa biến phụ thuộc và các biến độc lập trong mô hình một cách tương đối.

2.2.2.a Các giả thuyết của mô hình hồi quy bội

- Giả thiết 1: Việc ước lượng được dựa trên cơ sở mẫu ngẫu nhiên.
- Giả thiết 2: Kỳ vọng của sai số ngẫu nhiên tại mỗi giá trị $(X_{1i}, X_{2i}, \ldots, X_{ki})$ bằng 0:

$$\mathbb{E}(\varepsilon_i | X_{1i}, X_{2i}, \ldots, X_{ki}) = 0$$

- Giả thiết 3: Phương sai sai số ngẫu nhiên tại các giá trị $(X_{1i}, X_{2i}, \ldots, X_{ki})$ đều bằng nhau:

$$\mathrm{Var}(\varepsilon_i | X_{1i}, X_{2i}, \ldots, X_{ki}) = \sigma^2$$

- Giả thiết 4: Giữa các biến độc lập X_j không có quan hệ cộng tuyến hoàn hảo, nghĩa là không tồn tại hằng số $\lambda_1, \lambda_2, \ldots, \lambda_k$ không đồng thời bằng 0 sao cho:

$$\lambda_1 X_1 + \lambda_2 X_2 + \cdots + \lambda_k X_k = 0$$

2.2.2.b Phương pháp bình phương nhỏ nhất (OLS)

Xét mô hình hồi quy tuyến tính bội có k biến:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

Giả sử có một mẫu quan sát với giá trị thực tế là $(Y_i, X_{1i}, X_{2i}, \ldots, X_{ki})$ với $i = 1, 2, \ldots, n$. Ta sẽ sử dụng thông tin từ mẫu để xây dựng các ước lượng $\hat{\beta}_j$ của các hệ số β_j.
Hàm hồi quy mẫu:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \cdots + \hat{\beta}_k X_k$$

Tại mỗi quan sát i:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki}$$

Phần dư:

$$e_i = Y_i - \hat{Y}_i$$

Mục tiêu của phương pháp OLS là:

$$\min_{\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_k} \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \cdots - \hat{\beta}_k X_{ki})^2$$

Để cực tiểu hóa biểu thức này, ta giải hệ phương trình:

$$\sum_{i=1}^{n} X_{ji}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \cdots - \hat{\beta}_k X_{ki}) = 0$$

$$j = 0, 1, \ldots, k$$

Với điều kiện số quan sát trong mẫu lớn hơn số hệ số hồi quy cần ước lượng và giả thiết 4 được thỏa mãn, hệ phương trình trên có nghiệm duy nhất.

Các giá trị ước lượng bằng phương pháp OLS được xem là các ước lượng điểm tốt nhất không chệch (BLUE).

2.2.3 Độ phù hợp của hàm hồi quy

Hệ số xác định bội

Ký hiệu:
$TSS = \sum_{i=1}^{n}(Y_i - \bar{Y})^2$ (Tổng bình phương độ lệch toàn phần)
$ESS = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2$ (Tổng bình phương do hồi quy)
$RSS = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$ (Tổng bình phương phần dư)

Khi đó:

$$TSS = ESS + RSS$$

Định nghĩa hệ số xác định R^2:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

Ý nghĩa: R^2 biểu diễn tỷ lệ thay đổi của biến phụ thuộc được giải thích bởi các biến độc lập.

- $R^2 = 1$: 100% sự thay đổi của Y được giải thích bởi các biến X.
- $R^2 = 0$: Các biến X không giải thích được sự thay đổi nào của Y.

Hệ số xác định đã hiệu chỉnh

Một tính chất quan trọng của R^2 là nó sẽ tăng khi ta đưa thêm biến độc lập vào mô hình.

Dễ dàng thấy rằng TSS không phụ thuộc vào số biến giải thích trong mô hình, nhưng RSS lại tăng. Do đó, nếu tăng số biến độc lập vào mô hình thì R^2 cũng tăng. Như vậy, việc đưa thêm một biến số bất kỳ vào mô hình nói chung sẽ làm gia tăng R^2, không kể nó có giúp giải thích thêm cho biến phụ thuộc hay không.

Điều này xảy ra vì R^2 chưa phải là thước đo tốt khi muốn so sánh các mô hình với số biến khác nhau.

Để giải quyết vấn đề thiếu sót này, ta xem xét khái niệm hệ số xác định đã hiệu chỉnh, ký hiệu là $\bar{R}^2$, và được xác định như sau:

$$\bar{R}^2 = 1 - (1 - R^2) \cdot \frac{n-1}{n-k}$$

Khi số biến độc lập tăng lên thì $\bar{R}^2$ tăng lên nhưng tăng chậm hơn so với R^2.

Giá trị $\bar{R}^2$ thường được sử dụng thay vì R^2 khi so sánh hai mô hình hồi quy có số lượng biến độc lập khác nhau. Trong thực tế, $\bar{R}^2$ được dùng nhiều hơn vì R^2 rất dễ dẫn đến kết luận sai rằng mô hình phù hợp chỉ dựa vào số lượng biến giải thích lớn.

Do đó, $\bar{R}^2$ được coi là một tiêu chí đánh giá mô hình hợp lý hơn khi xét đến cả số biến độc lập và số lượng quan sát.

2.2.4 Khoảng tin cậy và kiểm định các hệ số hồi quy

Ước lượng khoảng tin cậy đối với các hệ số hồi quy Mục đích của phân tích hồi quy không chỉ là suy đoán về các hệ số β_j $(j = 0, 1, 2, \ldots, k)$ mà còn là kiểm tra bản chất của mối quan hệ phụ thuộc. Do vậy, cần phải biết phân bố xác suất của các $\hat{\beta}_j$.

Với các giả thiết OLS, ta có $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$. Khi đó, các hệ số ước lượng tuân theo phân phối chuẩn:

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, se(\hat{\beta}_j))$$

$$t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t(n-k)$$

Trong đó, sai số chuẩn của $\hat{\beta}_j$ ký hiệu là $se(\hat{\beta}_j)$, được tính theo công thức:

$$se(\hat{\beta}_j) = \sqrt{\frac{\hat{\sigma}^2}{(1 - R_j^2) \cdot \sum x_{ji}^2}} = \sqrt{\frac{RSS}{n-k} \cdot \frac{1}{(1 - R_j^2) \cdot \sum x_{ji}^2}}$$

Ước lượng phương sai sai số dựa trên phần dư bình phương tối thiểu:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} e_i^2}{n-k}$$

Khoảng tin cậy hai phía với mức ý nghĩa α:

$$P\left(-t_{\alpha/2}(n-k) \leq \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \leq t_{\alpha/2}(n-k)\right) = 1 - \alpha$$

Kiểm định giả thuyết đối với β_j

Kiểm định ý nghĩa thống kê nhằm xác định xem biến giải thích x_j có thực sự ảnh hưởng đến biến phụ thuộc hay không.

Giả thuyết:

$$H_0 : \beta_j = 0 \quad (x_j \text{ không có tác động})$$
$$H_1 : \beta_j \neq 0 \quad (x_j \text{ có tác động})$$

Thống kê kiểm định:

$$t = \frac{\hat{\beta}_j - 0}{se(\hat{\beta}_j)} \sim t(n-k)$$

Kết luận:

- Nếu $|t| > t_{\alpha/2}(n-k)$ thì bác bỏ $H_0 \Rightarrow x_j$ có ý nghĩa thống kê.
- Nếu $\hat{\beta}_j < 0$: x_j có tác động ngược chiều.
- Nếu $\hat{\beta}_j > 0$: x_j có tác động thuận chiều.

2.3 Phân tích phương sai một yếu tố (Anova một nhân tố với cỡ mẫu cân bằng)

Phân tích phương sai môt nhân tố là phân tích ảnh hưởng của môt yếu tố nguyên nhân (dạng biến định tính) ảnh hưởng đến môt yếu tố kết quả (dạng biến định lượng) đang nghiên cứu. Cụ thể bao gồm các điểm như sau:

- Các tổng thể này có phân phối bình thường để kết quả kiểm định có độ chính xác cao.
- Các phương sai tổng thê bằng nhau, nếu không đồng nhất, các kết quả thống kê có thể không chính xác, dẫn đến việc đưa ra các kết luận sai về sự khác biệt giữa các nhóm.

- Các giả định quan sát được lấy mẫu là đôc lập nhau.

Trong ANOVA, chúng ta sẽ kiểm tra sự khác biệt giữa trung bình k. Với các dữ liệu có sẵn, ta có thể lập nên hai giả thuyết như sau:

- H_0: Cho rằng trung bình của k tổng thể đều bằng nhau : $\mu_1 = \mu_2 = \cdots = \mu_k$
- H_1: Tồn tại ít nhất một cặp trung bình tổng thể khác nhau (μ_i, μ_j) sao cho $\mu_i \neq \mu_j$

Từ giả thuyết đã cho, ta sẽ có các bước kiểm định sau:

Bước 1: Tính các trung bình mẫu của các nhóm *Ví dụ ta có bảng sau:*

	1	2	$\cdots$	k
1	X_{11}	X_{21}	$\cdots$	X_{k1}
2	X_{12}	X_{22}	$\cdots$	X_{k2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
n	X_{1n_1}	X_{2n_2}	$\cdots$	X_{kn_k}
Tổng cộng trung bình	$\overline{X}_1$	$\overline{X}_2$	$\cdots$	$\overline{X}_n$

Bảng 2: Bảng dữ liệu cho ANOVA

Tính trung bình mẫu của từng nhóm $X_1, X_2, \ldots, X_k$ theo công thức:

$$\overline{X}_i = \frac{1}{n_i}\sum_{j=1}^{n_i} X_{ij} \quad , i = 1, 2, \ldots, k$$

Tính trung bình của k mẫu, tức là trung bình của toàn bộ mẫu được khảo sát:

$$\overline{X} = \frac{\sum_{i=1}^{k} n_i \overline{X}_i}{\sum_{i=1}^{k} n_i}$$

Trong đó:

- μ_i: kỳ vọng (trung bình tổng thể của nhóm i)
- σ^2: phương sai tổng thể
- X_{ij}: quan sát thứ j trong nhóm i
- $\sum X_{ij}$: tổng các quan sát trong từng mẫu
- $\sum X_{ij}$ (toàn bộ): tổng tất cả các quan sát
- $\overline{X}_i$: trung bình các quan sát trong từng mẫu
- $\overline{X}$: trung bình tổng thể

Bước 2: Bảng phân tích phương sai (ANOVA)

Nguồn của sự biến thiên	Bậc tự do df	Tổng bình phương SS	Bình phương trung bình MS	Giá trị Thống kê kiểm định F
Nghiệm thức (giữa các nhóm)	k-1	SSB	MSB	
Sai số (trong các nhóm)	k(n - 1) = N - k	SSW	MSW	$F = \frac{MSB}{MSW}$
Tổng thể	kn - 1 = N - 1	SST		

Trong đó:

- Tổng thể:
  $SST = SSB + SSW = \sum_{i=1}^{k}\sum_{j=1}^{n}(X_{ij} - \bar{X})^2$
  $SS_1 = \sum_{j=1}^{n}(X_{1j} - \bar{X})^2$
  $SS_2 = \sum_{j=1}^{n}(X_{2j} - \bar{X})^2$

- Trung bình bình phương (MS):

  – Nghiệm thức (giữa các nhóm):
  $$MSB = \frac{SSB}{k-1}$$
  – Sai số (trong các nhóm):
  $$MSW = \frac{SSW}{k(n-1)}$$

- df - Bậc Tự Do
  – Giữa các nhóm: $df_1 = k - 1$
  – Trong các nhóm: $df_2 = k(n-1) = N - k$

- F: Giá trị thống kê của ANOVA

Để kiểm định giá trị thống kê F, ta sẽ sử dụng phân phối Fisher. f_α: điểm phân vị phải mức của phân phối Fisher.

Bước 3: Kiểm định giả thuyết
Nếu F $< F_\alpha$(k - 1; n - k)$\Rightarrow$ chấp nhận giả thuyết H_0 Bác bỏ giả thuyết H_0 khi F $>F_\alpha$(k - 1; n - k)
$F_\alpha(k-1; n-k)$ là giá trị giới hạn với:

- Bậc tự do $n_1 = k - 1$ (tra theo hàng đầu tiên)
- Bậc tự do $n_2 = n - k$ (tra theo cột đầu tiên)

Tùy vào mức ý nghĩa α phù hợp, ta so sánh giá trị F với giá trị $F_\alpha(k-1; n-k)$ để đưa ra kết luận thống kê.

3 Tiền xử lí số liệu

3.1 Đọc dữ liệu

Đọc dữ liệu từ file "cancer_reg.csv"

CODE

```
#Đọc data từ file csv
#Assume that the file has address "C:/User/Nguyn/Downloads/cancer_reg.csv"
cancer_reg <- read.csv("C:/Users/Nguyn/Downloads/cancer_reg.csv")
```

Kết quả thu được:

RESULT

```
> #Đọc data từ file csv
> #Assume that the file has address "C:/User/Nguyn/Downloads/cancer_reg.csv"
> cancer_reg <- read.csv("C:/Users/Nguyn/Downloads/cancer_reg.csv")
> head(cancer_reg, 3)
  avganncount avgdeathsperyear target_deathrate incidencerate medincome popest2015 povertypercent studypercap
1        1397              469            164.9         489.8     61898     260131           11.2   499.74820
2         173               70            161.3         411.6     48127      43269           18.6    23.11123
3         102               50            174.7         349.7     49348      21026           14.6    47.56016
           binnedinc medianage medianagemale medianagefemale                    geography percentmarried
1  (61494.5, 125635]      39.3          36.9            41.7    Kitsap County, Washington           52.5
2 (48021.6, 51046.4]      33.0          32.2            33.7  Kittitas County, Washington           44.5
3 (48021.6, 51046.4]      45.0          44.0            45.8 Klickitat County, Washington           54.2
  pctnohs18_24 pcths18_24 pctsomecol18_24 pctbachdeg18_24 pcths25_over pctbachdeg25_over pctemployed16_over
1         11.5       39.5            42.1             6.9         23.2              19.6               51.9
2          6.1       22.4            64.0             7.5         26.0              22.7               55.9
3         24.0       36.6              NA             9.5         29.0              16.0               45.9
  pctunemployed16_over pctprivatecoverage pctprivatecoveragealone pctempprivcoverage pctpubliccoverage
1                  8.0               75.1                      NA               41.6              32.9
2                  7.8               70.2                    53.8               43.6              31.1
3                  7.0               63.7                    43.5               34.9              42.1
  pctpubliccoveragealone pctwhite  pctblack  pctasian pctotherrace pctmarriedhouseholds birthrate
1                   14.0 81.78053 2.5947283 4.8218571     1.843479             52.85608  6.118831
2                   15.3 89.22851 0.9691025 2.2462326     3.741352             45.37250  4.333096
3                   21.1 90.92219 0.7396734 0.4658982     2.747358             54.44487  3.729488
>
```

Tiếp theo, ta tìm số quan sát và số cột (biến) của dữ liệu:

CODE

```
> dim(cancer_reg)
[1] 3047   33
```

Ta thấy dữ liệu có 3047 quan sát và 33 cột.

3.2 Làm sạch dữ liệu

3.2.1 Chọn lọc dữ liệu

Ta chọn các biến quan trọng và lưu nó vào data:

CODE

```
#Lựa chọn các biến cần thiết
#Sử dụng lệnh select từ thư viện dplyr
new_cancer_data <- cancer_reg %>% select("avganncount", "avgdeathsperyear",
                                         "target_deathrate", "incidencerate",
                                         "medincome", "popest2015", "povertypercent",
                                         "studypercap", "binnedinc",
                                         "medianage", "birthrate",
                                         "geography")
```

Kết quả thu được

RESULT

Filter

	avgannccount	avgdeathsperyear	target_deathrate	incidencerate	medincome	popest2015	povertypercent	studypercap	binnedinc	medianage	birthrate	geography
1	1397.000	469	164.9	489.8000	61898	260131	11.2	499.748204	(61494.5, 125635]	39.3	6.1188310	Kitsap County, Washington
2	173.000	70	161.3	411.6000	48127	43269	18.6	23.111234	(48021.6, 51046.4]	33.0	4.3330956	Kittitas County, Washington
3	102.000	50	174.7	349.7000	49348	21026	14.6	47.560164	(48021.6, 51046.4]	45.0	3.7294878	Klickitat County, Washington
4	427.000	202	194.8	430.4000	44243	75882	17.1	342.637253	(42724.4, 45201]	42.8	4.6038408	Lewis County, Washington
5	57.000	26	144.4	350.1000	49955	10321	12.5	0.000000	(48021.6, 51046.4]	48.3	6.7966574	Lincoln County, Washington
6	428.000	152	176.0	505.4000	52313	61023	15.6	180.259902	(51046.4, 54545.6]	45.4	4.9644760	Mason County, Washington
7	250.000	97	175.9	461.8000	37782	41516	23.2	0.000000	(37413.8, 40362.7]	42.6	4.2043173	Okanogan County, Washington
8	146.000	71	183.6	404.0000	40189	20848	17.8	0.000000	(37413.8, 40362.7]	51.7	5.8891790	Pacific County, Washington
9	88.000	36	190.5	459.4000	42579	13088	22.3	0.000000	(40362.7, 42724.4]	49.3	5.5875831	Pend Oreille County, Washington
10	4025.000	1380	177.8	510.9000	60397	843954	13.1	427.748432	(54545.6, 61494.5]	35.8	5.5334302	Pierce County, Washington
11	113.000	36	121.4	413.3000	54721	16252	12.7	0.000000	(54545.6, 61494.5]	54.4	4.5861298	San Juan County, Washington
12	740.000	269	172.7	499.3000	51395	121846	15.7	837.122269	(51046.4, 54545.6]	41.0	5.8181533	Skagit County, Washington
13	55.000	26	188.3	398.9000	52673	11339	12.6	0.000000	(51046.4, 54545.6]	45.2	4.8055920	Skamania County, Washington
14	3438.000	1118	165.3	493.4000	71890	772501	9.9	138.511148	(61494.5, 125635]	37.6	4.7292511	Snohomish County, Washington
15	2265.000	901	171.0	440.7000	50083	490945	16.3	462.373586	(48021.6, 51046.4]	37.2	5.3558359	Spokane County, Washington
16	251.000	106	174.2	423.8000	43823	43791	19.3	0.000000	(42724.4, 45201]	46.2	3.6310821	Stevens County, Washington
17	1390.000	483	169.9	495.9000	61653	269536	11.9	207.764454	(61494.5, 125635]	38.5	5.1801552	Thurston County, Washington
18	32.000	12	153.8	463.2000	51022	4042	13.9	0.000000	(48021.6, 51046.4]	52.1	0.5354752	Wahkiakum County, Washington
19	305.000	120	162.8	442.5000	49819	60338	15.7	464.052504	(48021.6, 51046.4]	36.9	4.1387109	Walla Walla County, Washington
20	1081.000	367	163.3	490.9000	53733	212284	15.7	249.665542	(51046.4, 54545.6]	36.5	4.4729858	Whatcom County, Washington
21	134.000	50	140.8	390.5000	41837	48177	28.4	0.000000	(40362.7, 42724.4]	24.2	3.3041590	Whitman County, Washington
22	958.000	403	169.4	411.0000	44342	248830	20.5	301.410602	(42724.4, 45201]	32.5	6.5606117	Yakima County, Washington
23	94.000	41	189.7	445.2000	35615	16704	21.5	0.000000	(34218.1, 37413.8]	41.5	2.2928609	Barbour County, West Virginia

Showing 1 to 23 of 3,047 entries, 12 total columns

3.2.2 Thêm và xóa biến

Để cải thiện việc thống kê theo tiểu bang, chúng ta sẽ thêm biến "State". Dữ liệu gốc hiện tại phân chia theo cấp hạt bằng biến "Geography", với 3047 mẫu tương ứng với 3047 hạt. Bằng cách sử dụng biến "State", chúng ta sẽ nhóm các mẫu này theo 51 bang, giúp giảm số lượng mẫu và tạo điều kiện thuận lợi cho việc quan sát và phân tích dữ liệu.

CODE

```
#Điều chỉnh bảng dữ liệu
#Cho phép thống kê theo đơn vị hành chính địa lý cấp bang (State)
# Thêm một cột 'State' để tách tiểu bang ra (sử dụng gsub)
new_cancer_data$State <- gsub(".*, ", "", new_cancer_data$geography)
```

Kết quả thu được

RESULT

Filter

	avgannccount	avgdeathsperyear	target_deathrate	incidencerate	medincome	popest2015	povertypercent	studypercap	binnedinc	medianage	birthrate	geography	State
1	1397.000	469	164.9	489.8000	61898	260131	11.2	499.748204	(61494.5, 125635]	39.3	6.1188310	Kitsap County, Washington	Washington
2	173.000	70	161.3	411.6000	48127	43269	18.6	23.111234	(48021.6, 51046.4]	33.0	4.3330956	Kittitas County, Washington	Washington
3	102.000	50	174.7	349.7000	49348	21026	14.6	47.560164	(48021.6, 51046.4]	45.0	3.7294878	Klickitat County, Washington	Washington
4	427.000	202	194.8	430.4000	44243	75882	17.1	342.637253	(42724.4, 45201]	42.8	4.6038408	Lewis County, Washington	Washington
5	57.000	26	144.4	350.1000	49955	10321	12.5	0.000000	(48021.6, 51046.4]	48.3	6.7966574	Lincoln County, Washington	Washington
6	428.000	152	176.0	505.4000	52313	61023	15.6	180.259902	(51046.4, 54545.6]	45.4	4.9644760	Mason County, Washington	Washington
7	250.000	97	175.9	461.8000	37782	41516	23.2	0.000000	(37413.8, 40362.7]	42.6	4.2043173	Okanogan County, Washington	Washington
8	146.000	71	183.6	404.0000	40189	20848	17.8	0.000000	(37413.8, 40362.7]	51.7	5.8891790	Pacific County, Washington	Washington
9	88.000	36	190.5	459.4000	42579	13088	22.3	0.000000	(40362.7, 42724.4]	49.3	5.5875831	Pend Oreille County, Washington	Washington
10	4025.000	1380	177.8	510.9000	60397	843954	13.1	427.748432	(54545.6, 61494.5]	35.8	5.5334302	Pierce County, Washington	Washington
11	113.000	36	121.4	413.3000	54721	16252	12.7	0.000000	(54545.6, 61494.5]	54.4	4.5861298	San Juan County, Washington	Washington
12	740.000	269	172.7	499.3000	51395	121846	15.7	837.122269	(51046.4, 54545.6]	41.0	5.8181533	Skagit County, Washington	Washington
13	55.000	26	188.3	398.9000	52673	11339	12.6	0.000000	(51046.4, 54545.6]	45.2	4.8055920	Skamania County, Washington	Washington
14	3438.000	1118	165.3	493.4000	71890	772501	9.9	138.511148	(61494.5, 125635]	37.6	4.7292511	Snohomish County, Washington	Washington
15	2265.000	901	171.0	440.7000	50083	490945	16.3	462.373586	(48021.6, 51046.4]	37.2	5.3558359	Spokane County, Washington	Washington
16	251.000	106	174.2	423.8000	43823	43791	19.3	0.000000	(42724.4, 45201]	46.2	3.6310821	Stevens County, Washington	Washington
17	1390.000	483	169.9	495.9000	61653	269536	11.9	207.764454	(61494.5, 125635]	38.5	5.1801552	Thurston County, Washington	Washington
18	32.000	12	153.8	463.2000	51022	4042	13.9	0.000000	(48021.6, 51046.4]	52.1	0.5354752	Wahkiakum County, Washington	Washington
19	305.000	120	162.8	442.5000	49819	60338	15.7	464.052504	(48021.6, 51046.4]	36.9	4.1387109	Walla Walla County, Washington	Washington
20	1081.000	367	163.3	490.9000	53733	212284	15.7	249.665542	(51046.4, 54545.6]	36.5	4.4729858	Whatcom County, Washington	Washington

Showing 1 to 20 of 3,047 entries, 13 total columns

3.3 Xử lý dữ liệu khuyết

Trước tiên, ta kiểm tra dữ liệu khuyết trong mẫu dư liệu đã lọc biến:

CODE

```
#Kiểm tra dữ liệu khuyết
#Đã lọc
freq.na(new_cancer_data)
```

Các biến được lựa chọn không tồn tại dữ liệu khuyết nên không cần hiệu chuẩn

CODE

```
> freq.na(new_cancer_data)
                  missing %
avganncount             0 0
avgdeathsperyear        0 0
target_deathrate        0 0
incidencerate           0 0
medincome               0 0
popest2015              0 0
povertypercent          0 0
studypercap             0 0
binnedinc               0 0
medianage               0 0
birthrate               0 0
geography               0 0
State                   0 0
```

4 Thống kê mô tả

4.1 Tính toán thống kê mẫu

Chúng ta thực hiện tính các đại lượng bao gồm:

Đại lượng	Ký hiệu	Ý nghĩa
Trung bình mẫu	$\bar{x}$	Giá trị trung bình dữ liệu mẫu
Phương sai mẫu	s^2	Mức độ phân tán dữ liệu
Độ lệch chuẩn mẫu	s	Mức độ chênh lệch khỏi trung bình
Trung vị	–	Giá trị giữa
Mode (mốt)	–	Giá trị lặp lại nhiều nhất
Min/Max	–	Giá trị nhỏ nhất/lớn nhất

Code R:

```
# Lọc các biến cụ thể từ dữ liệu
selected_vars <- cancer_reg %>% select(avganncount, avgdeathsperyear,
                                       povertypercent, medincome
                                       )

summary_data <- sapply(selected_vars, function(x) {
  c(
    Mean = mean(x), #trung binh
    SD = sd(x), #Do lech chuan
    Min = min(x),#Gia tri nho nhat
    Max = max(x), #Gia tri lon nhat
    PV1 = quantile(x, 0.25), #phan vi 1
    Median = median(x), #Trung vi
    PV3 = quantile(x, 0.75)  #Phan vi 3

  )
})
t(summary_data)
```

Kết quả phép tính:

```
> t(summary_data)
                    Mean           SD     Min      Max  PV1.25%  Median PV3.75%
avganncount       606.33854  1416.356223     6.0  38150.0    76.00   171.0   518.0
avgdeathsperyear  185.96587   504.134286     3.0  14010.0    28.00    61.0   149.0
povertypercent     16.87818     6.409087     3.2     47.4    12.15    15.9    20.4
medincome       47063.28192 12040.090836 22640.0 125635.0 38882.50 45207.0 52492.0
```

Nhận xét:

- avganncount (Số ca mắc trung bình hàng năm):
  - Trung bình (Mean): 606.34
  - Độ lệch chuẩn (SD): 1416.36 → rất lớn so với trung bình, cho thấy dữ liệu phân tán mạnh.
  - Min - Max: 6 đến 38,150 → khoảng giá trị rất rộng.
  - Median: 171 ⟶ thấp hơn nhiều so với trung bình ⟹ phân phối lệch phải (có nhiều giá trị cao bất thường).
  - Khoảng phân vị 1.25% - 3.75%: 76 đến 518
- avgdeathsperyear (Số ca tử vong trung bình hàng năm):

  - Trung bình: 185.97
  - Độ lệch chuẩn: 504.13 → cũng rất cao
  - Min - Max: 3 đến 14,010
  - Median: 61 → cũng cho thấy lệch phải
  - PV1.25% - PV3.75%: 28 đến 149

- povertypercent (Tỷ lệ nghèo):
  - Trung bình: 16.88%
  - Độ lệch chuẩn: 6.41 → mức biến động tương đối nhỏ
  - Min - Max: 3.2
  - Median: 15.9%
  - Phân bố: Gần như đối xứng quanh trung bình

- medincome (Thu nhập trung vị):
  - Trung bình: $47,063.28
  - Độ lệch chuẩn: $12,040.09
  - Min - Max: $22,640 đến $125,635
  - Median: $45,207 ⟶ khá gần trung bình
  - PV1.25% - PV3.75%: $38,882.5 đến $52,492
  - Phân bố: Tương đối cân đối nhưng có một số giá trị rất cao (outlier)

4.2 Mô tả dữ liệu bằng đồ thị

4.2.1 Histogram (Biểu đồ tần suất)

Khái niệm: Biểu đồ histogram là một dạng biểu đồ cột dùng để thể hiện tần suất xuất hiện của các giá trị trong một tập dữ liệu. Histogram chia dữ liệu thành các khoảng (bins) và đếm số lần các giá trị rơi vào từng khoảng.

Cách xem biểu đồ:

- Trục hoành (X) thể hiện giá trị log10 của biến avgdeathsperyear – tức là số ca tử vong trung bình mỗi năm được chuyển đổi theo thang logarit cơ số 10 để giảm độ lệch.
- Trục tung (Y) thể hiện tần suất xuất hiện của từng khoảng giá trị sau khi đã logarit hóa.
- Mỗi cột biểu diễn số lượng quan sát có giá trị log10 của avgdeathsperyear rơi vào khoảng tương ứng.
- Dữ liệu nghiêng phải: phần lớn giá trị nhỏ, nhưng có một số rất lớn (dạng phân phối lệch phải – right skewed), vì thế logarit giúp làm "tròn" phân phối hơn.

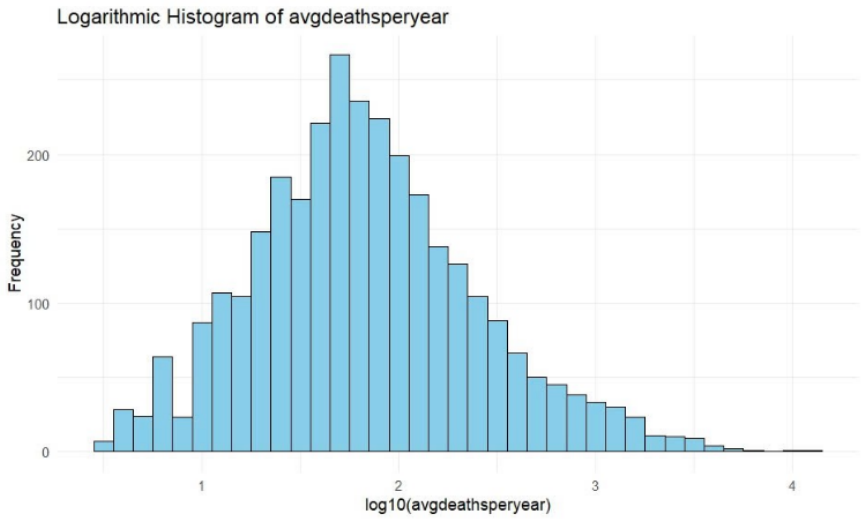

Hình 1: Biểu đồ tần suất theo thang logarit của biến avgdeathsperyear

Code R:

```
#Histogram cho biến avgdeathsperyear
#Có chênh lệch rất lớn giữa các giá trị nên sử dụng log10 để giảm bề rộng trục x
ggplot(selected_vars, aes(x = log10(.data[["avgdeathsperyear"]]))) +
  geom_histogram(binwidth = 0.1, color = "black", fill = "skyblue") +
  labs(title = "Logarithmic Histogram of avgdeathsperyear",
       x = "log10(avgdeathsperyear)",
       y = "Frequency") +
  theme_minimal()
```

Nhận xét:

Biểu đồ histogram theo thang logarit cho thấy phân phối của số ca tử vong trung bình mỗi năm không đối xứng, tập trung nhiều ở vùng log10 từ 1.5 đến 2.5. Điều này phản ánh rằng phần lớn các khu vực có số ca tử vong từ khoảng 30 đến 300 mỗi năm, trong khi chỉ một số ít khu vực có số ca tử vong vượt mức 1000.

4.2.2 Boxplot (Biểu đồ hộp)

Khái niệm: Boxplot (biểu đồ hộp) là công cụ trực quan hóa dùng để mô tả sự phân bố của một biến số liên tục và phát hiện các giá trị ngoại lai (outliers). Biểu đồ này thể hiện các thông số tóm tắt như: trung vị, tứ phân vị (Q1, Q3), giá trị nhỏ nhất và lớn nhất trong giới hạn, cùng với các điểm ngoại lai.
Cách xem biểu đồ:

- Trục tung (Y) biểu diễn biến medincome – thu nhập trung vị.
- Hộp chính biểu diễn khoảng từ Q1 (25%) đến Q3 (75%), với đường kẻ giữa là trung vị (Median = 45,207).
- Các đường "râu" mở rộng đến các giá trị không phải là ngoại lai.
- Các dấu chấm (•) nằm trên râu thể hiện các giá trị ngoại lai – những quan sát có medincome rất cao so với phần lớn dữ liệu (ví dụ >100,000).

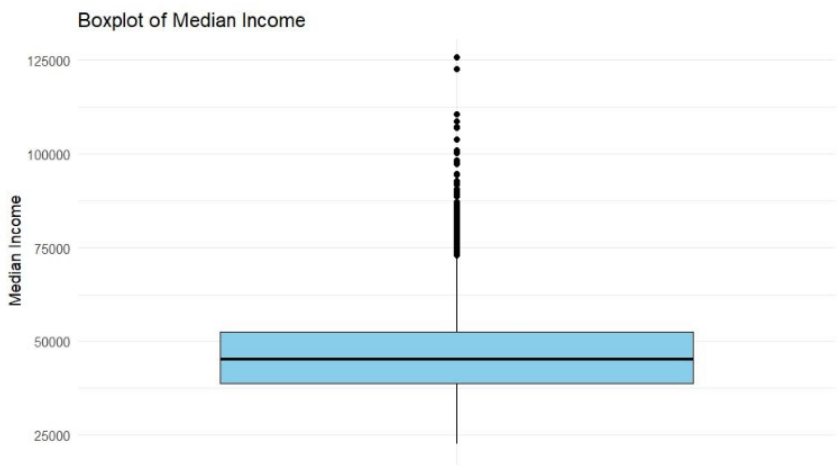

Hình 2: Boxplot (biểu đồ hộp) của thu nhập trung vị (Median Income)

Code R:

```
# Vẽ boxplot cho medincome
ggplot(selected_vars, aes(x = "", y = medincome)) +
  geom_boxplot(fill = "skyblue", color = "black") +
  labs(title = "Boxplot of Median Income",
       x = "",
       y = "Median Income") +
  theme_minimal()
```

Nhận xét:
Đường kẻ giữa hộp cho biết thu nhập trung vị của các khu vực nằm khoảng gần 45.000 – 50.000 USD. Phần lớn dữ liệu (50%) nằm trong khoảng giữa Q1 và Q3 (từ 40.000 đến 55.000 USD), cho thấy đa số các khu vực có thu nhập trung bình ổn định. Có nhiều điểm ngoại lai (outliers) nằm phía trên → biểu thị một số khu vực có thu nhập trung vị cao vượt trội, gây nên phân phối lệch phải (positive skewed). Những dấu chấm trên cùng là các khu vực có thu nhập trung vị rất cao (trên 75.000 USD, thậm chí trên 125.000 USD).

4.2.3 Scatter Plot (Biểu đồ phân tán)

Khái niệm: Scatter plot (biểu đồ phân tán) được sử dụng để mô tả mối quan hệ giữa hai biến định lượng. Mỗi điểm trên đồ thị đại diện cho một quan sát (một dòng dữ liệu) với hai giá trị tương ứng trên hai trục.
Cách xem biểu đồ:

- Trục hoành (X) biểu diễn biến povertypercent – tỷ lệ nghèo tại từng khu vực.
- Trục tung (Y) biểu diễn biến targetdeathrate – tỷ lệ tử vong mục tiêu.
- Mỗi chấm xanh biểu diễn một khu vực nhất định với giá trị tương ứng của tỷ lệ nghèo và tỷ lệ tử vong.
- Nhìn chung có xu hướng tương quan dương nhẹ: những nơi có tỷ lệ nghèo cao thường có tỷ lệ tử vong cao hơn, nhưng mối quan hệ không hoàn toàn tuyến tính.

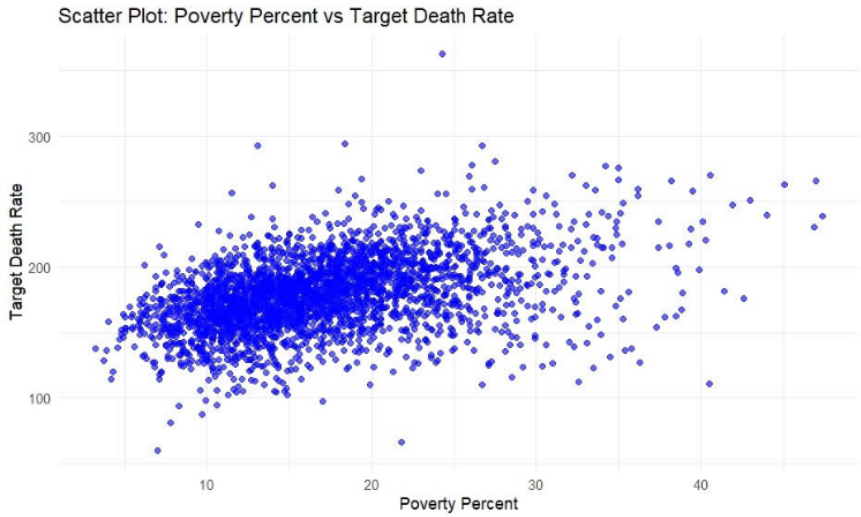

Hình 3: Biểu đồ phân tán của Tỷ lệ nghèo (Poverty Percent)
với Tỷ lệ tử vong mục tiêu (Target Death Rate)

Code R:

```
#Vẽ scatter plot cho povertypercent và target_deathrate
ggplot(cancer_reg, aes(x = povertypercent, y = target_deathrate)) +
  geom_point(color = "blue", alpha = 0.6) +
  labs(title = "Scatter Plot: Poverty Percent vs Target Death Rate",
       x = "Poverty Percent",
       y = "Target Death Rate") +
  theme_minimal()
```

Nhận xét: Có xu hướng tương quan dương nhẹ: Khi tỷ lệ nghèo tăng, tỷ lệ tử vong mục tiêu cũng có xu hướng tăng. Tuy nhiên, mối quan hệ không mạnh, vì các điểm phân tán khá rộng và không tạo thành một đường rõ ràng. Đa số điểm dữ liệu tập trung trong khoảng:

- Tỷ lệ nghèo: 5% – 20%
- Tỷ lệ tử vong: 150 – 225

Có một số điểm ngoại lai nổi bật, đặc biệt là:

- Các khu vực có tỷ lệ nghèo > 30
- Tỷ lệ tử vong vượt 300

5 Thống kê suy diễn

5.1 Phân tích các hệ số tương quan Pearson giữa các biến trong tập dữ liệu và tỷ lệ ung thư tại Mỹ

5.1.1 Mục tiêu

Sử dụng thư viện gplots để hiện thực đồ thị biểu diễn mức độ tương quan giữa các biến trong tập dữ liệu đã cho.

5.1.2 Thực hiện

Đầu tiên, dựa trên lý thuyết về Hệ số tương quan Pearson, ta quy ước các giá trị r trong biểu đồ như sau:

- $|r| < 0.1$: mối tương quan rất yếu
- $|r| < 0.3$: mối tương quan yếu
- $|r| < 0.5$: mối tương quan trung bình
- $|r| \geq 0.5$: mối tương quan mạnh

Sau đó, ta tiến hành vẽ đồ thị với thư viện gplots.

```
# Vẽ heatmap với số hiển thị
library(ggplot2)
ggplot(data = melted_cor, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(value, 2)), color = "black", size = 4) + # Hiển thị số
  scale_fill_gradient2(low = "blue", high = "red", mid = "white",
                       midpoint = 0, limit = c(-1, 1), space = "Lab",
                       name="Correlation") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1)) +
  labs(title = "Heatmap of Variables Correlation",
       x = "", y = "")
```

5.1.3 Kết quả

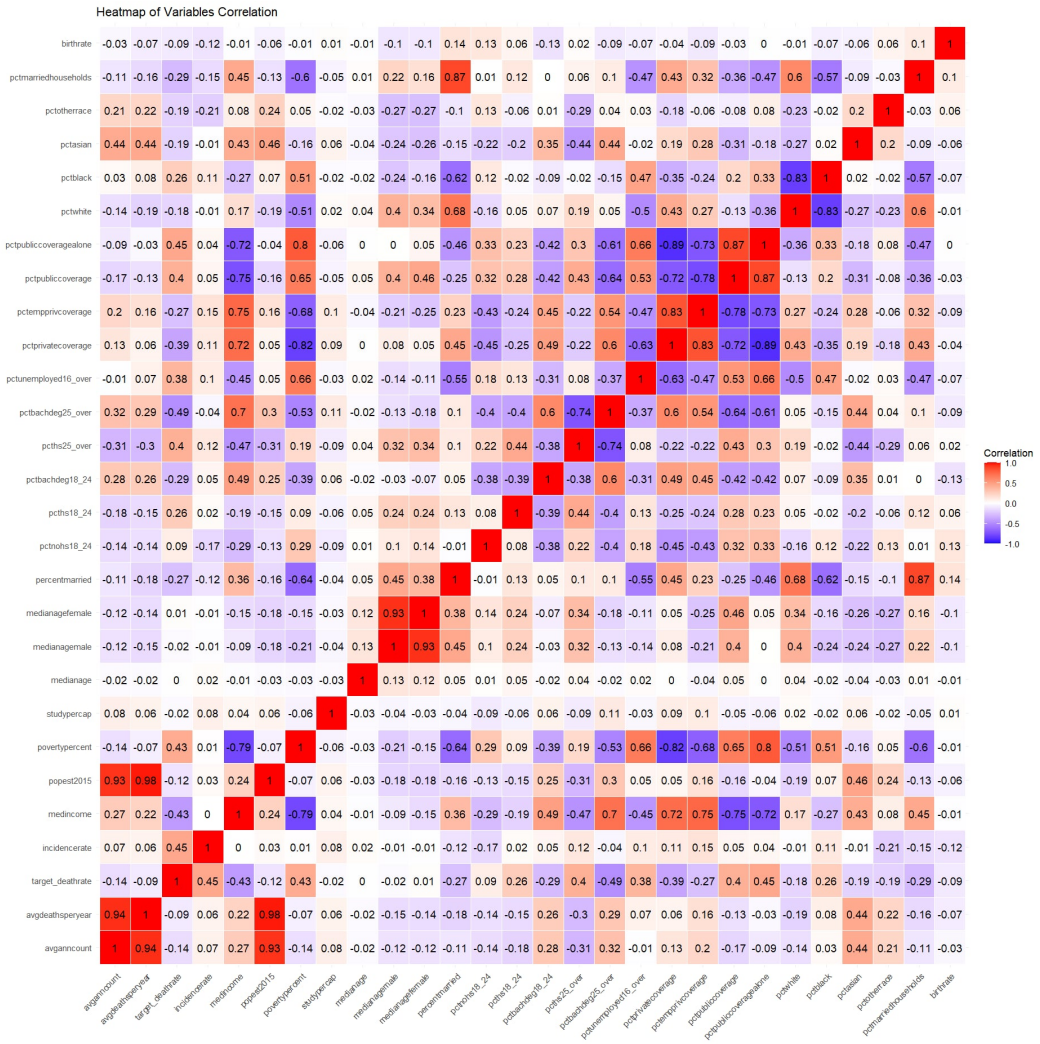

Hình 4: Bảng hệ số tương quan giữa các biến

5.1.4 Nhận xét

Dựa vào biểu đồ thể hiện mức độ tương quan giữa các biến trong tập dữ liệu, bỏ qua các ô mang giá trị 1.0 biểu thị cho mối tương quan tuyệt đối cũng như các biến , ta nhận thấy có sự tương quan giữa các biến avgdeathsperyear, popest2015, pcths25over, pctbachdeg25over, pctasian so với biến avaganncount. Tức là số lượng người mắc ung thư mỗi năm bị ảnh hưởng manh nhất bởi tỷ lệ người chết vì ung thư và dân số nước Mỹ mỗi năm.

5.2 So sánh số lượng ca mắc ung thư được chẩn đoán hằng năm tại các bang ở Mỹ

5.2.1 Mục tiêu

Sử dụng phương pháp phân tích phương sai ANOVA một nhân tố lên biến avganncount với mức ý nghĩa 0.05 để kiểm tra xem rằng liệu có sự khác biệt giữa số ca chẩn đoán ung thư giữa các bang hay không. Sau đó sử dụng phương pháp kiểm định phương sai đồng nhất Levene để kiểm tra kết quả của phân tích ANOVA.

Đầu tiên, ta sẽ đặt giả thuyết như sau:

- H_0 : Số ca mắc ung thư được chẩn đoán tại các bang ở Mỹ là như nhau
- H_1 : Có ít nhất một bang có số ca mắc ung thư được chẩn đoán khác với các bang còn lại.

Trong trường hợp giả thuyết H_0 bị bác bỏ, ta sẽ sử dụng TurkeyHSD để tiến hành so sánh cụ thể các cặp biến thuộc avganncount nhằm đánh giá mức độ khác biệt giữa số ca mắc ung thư được chẩn đoán hằng năm giữa các bang.

5.2.2 Kết quả

Đối với phân tích phương sai ANOVA, ta sử dụng hàm aov trong R để tính toán kết quả, sau đó gọi hàm summary để xuất kết quả ra màn hình.

```
> summary(res1.aov)
              Df    Sum Sq  Mean Sq F value Pr(>F)
State         50 1.253e+09 25052207   15.45 <2e-16 ***
Residuals   2996 4.858e+09  1621450
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Hình 5: Kết quả phân tích ANOVA của biến avganncount

Đối với phân tích Levene, ta sử dụng hàm leveneTest trong R để tính toán.

```
> #Levene Test
> leveneTest(avganncount ~ State, data = new_cancer_data)
Levene's Test for Homogeneity of Variance (center = median)
        Df F value    Pr(>F)
group   50   7.914 < 2.2e-16 ***
      2996
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Hình 6: Kết quả phân tích Levene của biến avgganncount

5.2.3 Nhận xét

Đối chiếu với kết quả, ta nhận thấy không có sự khác biệt quá nhiều về kết quả F của cả hai phương pháp. Đồng thời, vì F (F = 2e-16) bé hơn rất nhiều so với mức ý nghĩa 0.05, do đó ta sẽ bác bỏ H_0 và kết luận rằng tồn tại ít nhất 1 bang có số ca mắc ung thư được chẩn đoán khác với các bang khác tại Mỹ.

Comparison	diff	lwr	upr	p adj
Michigan-Connecticut	-1893.45	-3781.86	-5.03366	0.04813
Minnesota-Connecticut	-575.332	-2459.92	1309.26	1
Mississippi-Connecticut	-2354.99	-4244.41	-465.564	0.000717
Missouri-Connecticut	-2268.97	-4134.14	-403.794	0.001287
Montana-Connecticut	-2429.79	-4377.79	-481.794	0.000704
Nebraska-Connecticut	-2427.19	-4318.71	-535.665	0.000341
Nevada-Connecticut	-575.332	-2762.39	1611.728	1
New Hampshire-Connectic	-1781.9	-4201.54	637.7435	0.682626
New Jersey-Connecticut	-249.619	-2368.98	1869.74	1
New Mexico-Connecticut	-2265.97	-4282.34	-249.599	0.007031
New York-Connecticut	-836.5	-2752.82	1079.821	0.999976
North Carolina-Connecticu	-2062.94	-3937.89	-187.991	0.010502
North Dakota-Connecticut	-2470.39	-4410.19	-530.596	0.000415
Ohio-Connecticut	-1897.32	-3781.91	-12.73	0.04538
Oklahoma-Connecticut	-2297.03	-4191.9	-402.157	0.001396
Oregon-Connecticut	-1988.72	-3982.56	5.117375	0.051859
Pennsylvania-Connecticut	-1405.03	-3313.16	503.1019	0.68294
Rhode Island-Connecticut	-1362	-4270.05	1546.05	0.99984
South Carolina-Connecticut	-2020.78	-3974.82	-66.7442	0.030239
South Dakota-Connecticut	-2469.64	-4391.53	-547.763	0.000328
Tennessee-Connecticut	-2187.64	-4065.54	-309.744	0.003383
Texas-Connecticut	-2200.48	-4034.67	-366.281	0.001774
Utah-Connecticut	-2197.63	-4251	-144.259	0.0172
Vermont-Connecticut	-2284.57	-4545.37	-23.7698	0.042973

Hình 7: Minh họa kết quả so sánh tỷ lệ mắc ung thư tại các bang

Đối với bảng kết quả áp dụng TurkeyHSD, đối với các cặp biến có giá trị $p - value$ lớn hơn mức ý nghĩa 0.05, ta nhận thấy giá trị của biến bên trái sẽ lớn hơn biến bên phải và ngược lại đối với cặp biến có giá trị $p - value$ nhỏ hơn mức ý nghĩa.

5.3 Phân tích ảnh hưởng của các biến độc lập đến số ca tử vong vì ung thư tại Mỹ

5.3.1 Mục tiêu

Xây dựng mô hình hồi quy nhằm phân tích ảnh hưởng sự tác động của các biến độc lập đến số ca tử vong vì mắc ung thư tại Mỹ, ở đây là biến avgdeathperyear trong tập dữ liệu. Dựa vào bảng hệ số tương quan đã trình bày tại mục 5.1, ta chọn các biến độc lập có mức tương quan với biến avgdeathperyear từ trung bình trở lên (r > 0.3) sau: avggancount, popest2015, pcths25over, pctassian. Tuy nhiên, bởi vì tính chất của biến popest2015 và pcths25over,pctasian có phần tương tự nhau và để tránh xảy ra đa cộng tuyến, ta sẽ không thêm hai biến trên vào mô hình.

Đầu tiên, dựa trên công thức đã trình bày tại phần 2, chúng ta sẽ có công thức hồi quy như sau:

$$avgdeathsperyear = \beta_0 + \beta_1 * avganncount + \beta_2 * popest2015$$

Tiếp đó, ta tiến hành ước lượng hệ số β_i bằng hàm lm trong R.

```
#####################################################

# Tắt định dạng số mũ
options(scipen = 999)


# Thực hiện hồi quy tuyến tính
linear_model <- lm(avgdeathsperyear ~ avganncount + popest2015 , data = cleaned_data)

# Xem kết quả của mô hình hồi quy
summary(linear_model)
```

5.3.2 Kết quả

```
> # Xem kết quả của mô hình hồi quy
> summary(linear_model)

Call:
lm(formula = avgdeathsperyear ~ avganncount + popest2015, data = cleaned_data)

Residuals:
     Min       1Q   Median       3Q      Max 
-1399.93   -12.05    -1.72    15.49  1241.99 

Coefficients:
               Estimate  Std. Error t value             Pr(>|t|)    
(Intercept) 15.70114758  1.93626129   8.109 0.00000000000000732 ***
avganncount  0.08400165  0.00327877  25.620 < 0.0000000000000002 ***
popest2015   0.00116265  0.00001411  82.383 < 0.0000000000000002 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 96.2 on 3044 degrees of freedom
Multiple R-squared:  0.9636,	Adjusted R-squared:  0.9636 
F-statistic: 4.031e+04 on 2 and 3044 DF,  p-value: < 0.00000000000000022
```

Hình 8: Kết quả tính toán mô hình hồi quy

5.3.3 Nhận xét

Dựa trên kết quả trả về, ta xác định được:

$\beta_0 = 15.7011; \beta_1 = 0.0848; \beta_2 = 0.0012;$

Xem xét kết quả p-value, ta nhận thấy tất cả giá trị đều bé hơn mức ý nghĩa 5% ($p < 0.05$), vì vậy các biến trên đều có giá trị thống kê. Trong đó, avganncount và popest2015 đều tác động mạnh lên biến avgdeathsperyear. Ngoài ra, dựa trên hệ số β_i, ta có thể biết được ảnh hưởng của biến độc lập lên Y như thế nào, chẳng hạn với $\beta_1 = 0.0848$ ngụ ý rằng với 1 đơn vị avganncount sẽ làm tăng 0.0848 giá trị của biến avgdeathsperyear.

6 Thảo luận và mở rộng

6.1 Phân tích phương sai (ANOVA một nhân tố, cỡ mẫu cân bằng)

Ưu điểm:

- So sánh được nhiều nhóm cùng lúc.
- Hữu ích trong nghiên cứu thực nghiệm có nhiều điều kiện khác nhau.
- Kiểm tra sự khác biệt tổng thể: ANOVA kiểm tra giả thuyết không rằng trung bình của tất cả các nhóm là bằng nhau. Nếu bác bỏ giả thuyết không, chúng ta có bằng chứng cho thấy ít nhất một cặp trung bình nhóm khác nhau.

Nhược điểm:

- Giả định phân phối chuẩn và phương sai đồng đều giữa các nhóm.
- Không chỉ rõ nhóm nào khác biệt, cần post-hoc test (Tukey, Bonferroni,...).
- Giả định nghiêm ngặt: ANOVA dựa trên một số giả định quan trọng về dữ liệu. Việc vi phạm các giả định này có thể làm giảm độ tin cậy của kết quả kiểm định. Cỡ mẫu cân bằng có thể giúp làm giảm tác động của việc vi phạm tính chuẩn và phương sai đồng nhất ở một mức độ nào đó, nhưng vẫn cần kiểm tra.
- Không phù hợp với biến độc lập định lượng.
- Mất thông tin về sự thay đổi liên tục.
- Kết quả có thể bị ảnh hưởng bởi các ngoại lệ (outliers).

6.2 Phân tích hồi quy

6.2.1 Hồi quy tuyến tính đơn

Ưu điểm:

- Trực quan, dễ giải thích mối quan hệ giữa 2 biến.
- Dễ tính toán và kiểm định.
- Là cơ sở cho các mô hình phức tạp hơn.

Nhược điểm:

- Giả định tuyến tính có thể không đúng.
- Chỉ xét một biến độc lập $\rightarrow$ dễ bị sai lệch.
- Dễ bị ảnh hưởng bởi các ngoại lệ (outliers).
- Không mô hình hóa được tương tác.

6.2.2 Hồi quy tuyến tính bội

Ưu điểm:

- Mô hình hóa mối quan hệ phức tạp hơn giữa nhiều biến.
- Kiểm tra ảnh hưởng riêng rẽ của từng biến.
- Có thể mô hình hóa tương tác.

Nhược điểm:

- Cần kiểm tra các giả định như đa cộng tuyến, phân phối chuẩn phần dư,...
- Mô hình có thể quá phức tạp $\rightarrow$ dễ overfitting.
- Yêu cầu dữ liệu lớn hơn so với hồi quy đơn.

Tài liệu

[1] Nguyễn Đình Huy (Chủ biên), Đậu Thế Cấp, Lê Xuân Đại, Giáo trình Xác suất và Thống kê, 2022.

[2] How to Do Linear Regression in R "**link: https://www.datacamp.com/tutorial/linear-regression-R**"

[3] Levene's Test in R Programming "**link: https://www.geeksforgeeks.org/levenes-test-in-r-programming/**"

[4] How to Do a Tukey HSD Test with the Anova Command "**https://www.geeksforgeeks.org/how-to-do-a-tukey-hsd-test-with-the-anova-command-car-package-in-r/**"

[5] Correlation coefficient and correlation test in R "**https://www.r-bloggers.com/2020/05/correlation-coefficient-and-correlation-test-in-r/**'